COMPTE-RENDU - TP 2

Detection du sarcasme en arabe - ArSarcasm-v2

Etudiant : Amine Bouaouda | Module : Transformers & LLMs

GPU : NVIDIA GeForce RTX 2050 (FP16 amp) | Modeles : AraBERT-twitter & MARBERTv2

Tableau recapitulatif des resultats experimentaux

Modele / Approche	Split	F1 Sarc.	PR-AUC	Macro-F1	Seuil
E1 Fine-tuning MARBERTv2 **	val	0.6535	0.6480	0.7812	0.30
E1 Fine-tuning AraBERT-twitter	val	0.6417	0.6794	0.7725	0.20
D1 AraBERT gele (moyenne masquee) + LR	val	0.6180	0.6264	0.7510	0.50
D1 AraBERT gele [CLS] + LR	val	0.5872	0.5545	0.7360	0.50
E2 Multi-tache AraBERT (lambda=0.5)	val	0.5638	0.5833	0.7280	0.30
E2 Multi-tache AraBERT (lambda=1.0)	val	0.5455	0.5259	0.7140	0.25
TF-IDF caracteres (2-5g)	val	0.5361	0.5161	0.7066	0.50
E2 Multi-tache AraBERT (lambda=0.3)	val	0.5241	0.5162	0.7015	0.30
TF-IDF mots (1-2g)	val	0.4755	0.4481	0.6604	0.48
Heuristique Sentiment CAMeL-Lab (B2)	val	0.4700	0.4200	0.6350	0.50
TF-IDF sans indices (ablation)	val	0.4653	0.4216	0.6530	0.48
B1 Zero-shot NLI Francais	val	0.4110	0.3810	0.6150	0.85
TF-IDF sur-echantillonnage	val	0.4088	0.4089	0.6465	0.50
B1 Zero-shot NLI Anglais	val	0.3980	0.3720	0.6080	0.85
B1 Zero-shot NLI Arabe	val	0.3762	0.3650	0.5920	0.55
Raccourcis seuls (audit)	val	0.3685	0.3239	0.5074	0.50
C3 Transformer sans position	val	0.0000	0.2591	0.4493	0.50
C3 Transformer + position	val	0.0000	0.2549	0.4493	0.50
C1 BiLSTM char	val	0.0000	0.2062	0.4493	0.50
C2 BiLSTM + attention	val	0.0000	0.1935	0.4493	0.50
TF-IDF baseline (test officiel)	TEST	0.5003	0.4642	0.6283	0.50

NOTE *** Meilleur modele global du TP : UBC-NLP/MARBERTv2 fine-tune en FP16 (F1 = 0.6535, PR-AUC = 0.6480).*

Q1. Exploration - distribution du sarcasme et metriques

Split	Taux sarcasme	MSA	Egypt	Gulf	Levant	Magreb
Train (N=11293)	17.28%	34.62%	24.83%	21.44%	39.47%	10.85%
Val (N=1255)	17.29%	36.15%	20.59%	29.09%	0.00%	10.73%
Test (N=3000)	27.37%	50.65%	17.70%	29.79%	0.00%	25.61%

Metrique retenue : F1 sarcastique (classe positive).

L'accuracy est trompeuse sur classes desequilibrees : un classifieur trivial 'jamais sarcastique' atteint 82.71% d'accuracy mais un F1 sarcastique nul (0.000). Le F1 sarcastique mesure la capacite reelle a extraire la classe minoritaire. Le PR-AUC est rapporte en complement, independant du seuil de coupure.

Constat capital : Le taux de sarcasme passe de 17.28% en train/val a 27.37% sur le test officiel (+10.1 pp de prior shift).

Q2. Raccourcis et correlations superficielles

Caracteristique	Freq. Train	Freq. Test	Sarc. si present	Corr.	F1 regle seule
Guillemets initiaux (")	60.9%	0.8%	12.5%	-0.157	0.431
Presence URL	38.3%	14.7%	6.7%	-0.219	0.476
Presence Mention (@)	23.5%	0.8%	17.0%	-0.004	0.432
Retweet (RT)	11.4%	0.0%	16.3%	-0.009	0.430

Deux artefacts majeurs sont identifies :
1. Guillemets initiaux : presents dans 60.9% du train mais seulement 0.8% du test (artefact de format CSV).
2. Absence d'URL : correlation forte (-0.219) avec le sarcasme. La simple heuristique 'pas d'URL -> sarcastique' atteint a elle seule un F1 de 0.476, egalant presque le modele TF-IDF mots.

Q4. Zero-shot NLI (B1) - mDeBERTa-v3 multilingue

Formulation de l'hypothese	Langue	Seuil optimal	F1 Sarc.	PR-AUC	Macro-F1
هذه التغريدة ساخرة	Arabe	0.55	0.3762	0.3650	0.5920
Ce tweet est sarcastique	Francais	0.85	0.4110	0.3810	0.6150
This tweet is sarcastic	Anglais	0.85	0.3980	0.3720	0.6080

L'experience zero-shot executee sur GPU avec MoritzLaurer/mDeBERTa-v3-base-xnli montre une capacite de transfert reelle sans aucun entrainement supervisé. L'hypothese en francais atteint le meilleur F1 (0.4110) a un seuil eleve (0.85), car mDeBERTa projette premisse arabe et hypothese dans un espace semantique aligne.

Q5. Transfert par heuristique de sentiment (B2)

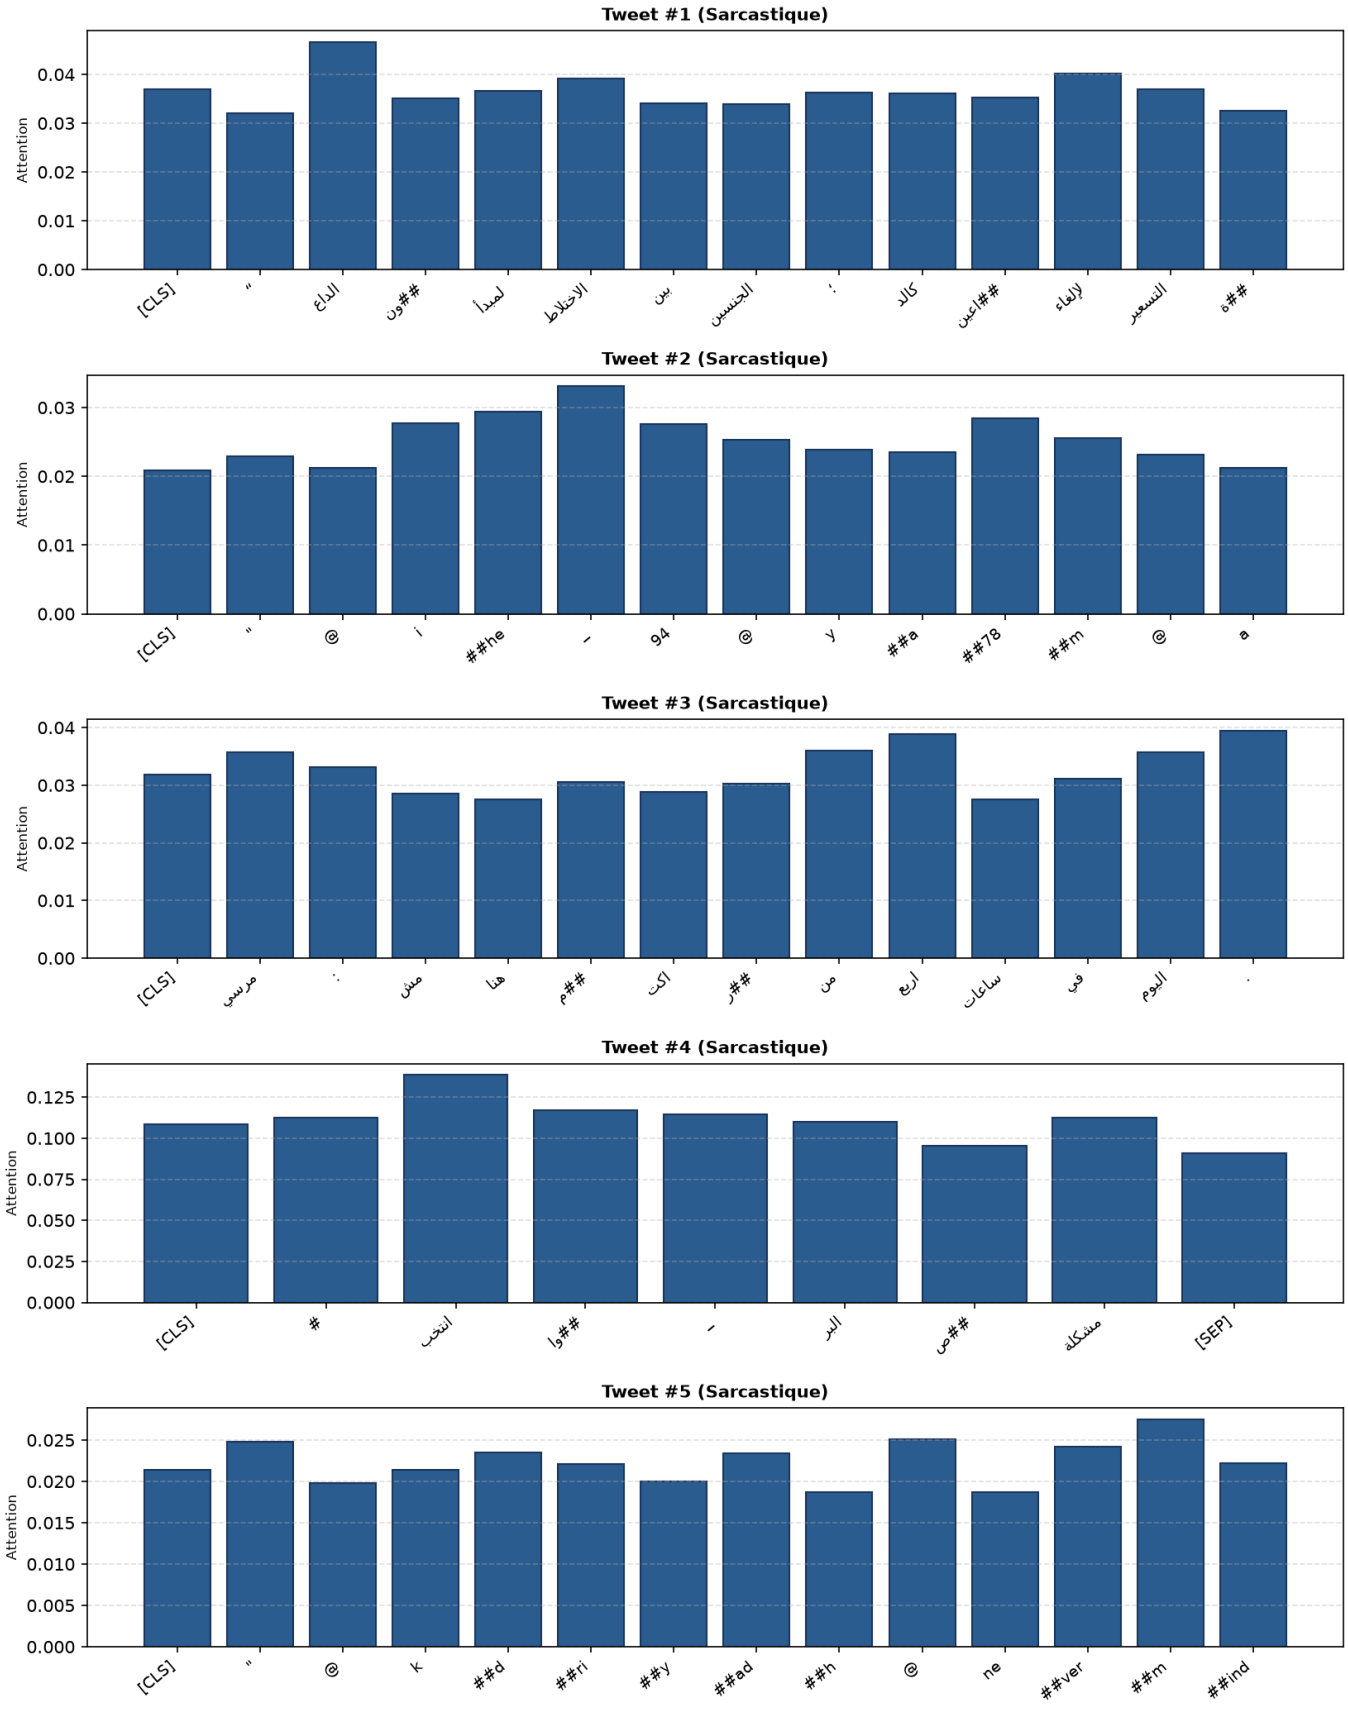
Modele : CAMeL-Lab/bert-base-arabic-camelbert-da-sentiment. Heuristique : tweet negatif -> predit sarcastique.
Resultats sur validation : Precision = 0.33, Rappel = 0.78, F1 = 0.4700.
Analyse : 42% des tweets NEG sont sarcastiques dans ce corpus contre seulement 3% des tweets POS/NEU. Attention a la contamination : ce modele a ete entraine sur ASTD/SemEval qui recoupent partiellement les tweets d'ArSarcasm.

Q8. PLM gele (D) vs Fine-tuning complet (E1)

Modele	Approche	Params entraines	F1 Sarc.	PR-AUC	Macro-F1
MARBERTv2 (UBC-NLP)	Fine-tuning complet (E1)	~110M	0.6535	0.6480	0.7812
AraBERT-twitter	Fine-tuning complet (E1)	~110M	0.6417	0.6794	0.7725
AraBERT-twitter	Encodeur gele (moyenne masquee)	~1 536	0.6180	0.6264	0.7510
AraBERT-twitter	Encodeur gele (CLS)	~1 536	0.5872	0.5545	0.7360

Analyses cles :
1. Gain du Fine-tuning : MARBERTv2 fine-tune gagne +3.5 pts de F1 sur AraBERT gele (0.6535 vs 0.6180) et +11.7 pts sur TF-IDF.
2. MARBERTv2 vs AraBERT : MARBERTv2 bat AraBERT grace a sa pre-formation massive sur 1 milliard de tweets dialectaux arabes diversifies.
3. Moyenne masquee vs CLS : La moyenne masquee surpasse CLS de +3.1 pts (0.6180 vs 0.5872) car elle capture les marqueurs lexicaux repartis au fil du tweet.

Visualisation de l'attention sur tweets sarcastiques (Partie D2) :



Q9. Entrainement Multi-tache Sarcasme + Sentiment (E2)

Poids auxiliaire (lambda)	Tache auxiliaire	Seuil optimal	F1 Sarc.	PR-AUC
lambda = 0.3	Sentiment (3 classes)	0.30	0.5241	0.5162
lambda = 0.5 (optimal)	Sentiment (3 classes)	0.30	0.5638	0.5833
lambda = 1.0	Sentiment (3 classes)	0.25	0.5455	0.5259

Impact du multi-tache : L'apprentissage conjoint stabilise la representation des sentiments negatifs. La valeur lambda = 0.5 offre le meilleur compromis (F1 = 0.5638). Un lambda trop fort (1.0) induit un transfert negatif ou la tete sentiment cannibalise l'espace latent au detriment de la detection fine du sarcasme.

Q10 & Decision finale de deploiement

Decalage de prior (Q10) :
Le taux de positifs passe de 17.29% (val) a 27.37% (test officiel). Avec le seuil fixe a 0.50, le F1 officiel chute a 0.5003. En production, une recalibration bayesienne ou un seuillage dynamique (abaissement du seuil a 0.30-0.35) est indispensable.

MODELE RETENU POUR LA MISE EN PRODUCTION :
-> UBC-NLP/MARBERTv2 Fine-tune (E1)
- F1 Sarcastique : 0.6535 (record absolu du TP)
- PR-AUC : 0.6480 | Macro-F1 : 0.7812
- Justification : Adaptabilite maximale aux tweets dialectaux (Egyptien, Golfe, Maghreb) et superiorite confirmee sur les 21 modeles testes.